

Propuesta de Arquitectura de Red Neuronal para IAm Phideus

Equipo AI Research

29 de julio de 2025

1. Antecedentes y contexto del proyecto

Antecedentes y contexto El proyecto IAm Phideus se dedica a detectar patrones de relaciones armónicas en paisajes sonoros naturales y señales biológicas. Los documentos internos propuestos por el usuario describen un flujo de procesamiento que comienza con la captura de señales en diferentes resoluciones mediante transformada corta de Fourier (STFT) y la detección de picos espectrales. A partir de los picos se calcula un conjunto de razones de frecuencia (f_i/f_j) para cada ventana temporal. Estas razones se representan en histogramas tanto lineales como logarítmicos. El proyecto busca evitar el sesgo de las escalas musicales humanas empleando histogramas lineales de razones armónicas y entrena un modelo que pueda reconocer patrones naturales de armonía en distintos contextos. Los documentos internos sugieren emplear un híbrido variational autoencoder (VAE) + red convolucional 1D (CNN), donde el VAE aprende una representación latente no supervisada de los histogramas de razones y la CNN actúa como clasificador. Se mencionan técnicas como convoluciones dilatadas, β -VAE o KL-annealing para lograr desenmarañar las variables latentes como aumentos de datos y regularización para mejorar la generalización. También se proponen alternativas como transformadores o modelos autoregresivos de estado para captar dependencias de largo alcance y la posible aplicación de aprendizaje contrastivo.


2. Avances recientes en arquitecturas de redes neuronales

Avances recientes en arquitecturas de redes neuronales relevantes (2019–2025) • **β -Variational Autoencoder y β -VAE con KL-annealing:** Un β -VAE modificado puede descubrir un conjunto de parámetros que describen procesos estocásticos y generar nuevas trayectorias a partir de ellos, una compresión que se logra eliminando latentes no esenciales mediante un término de regularización aumentado [169048481381521†L21-L33] [169048481381521†L137-L157]. Estas técnicas ayudan a capturar solo las relaciones armónicas esenciales y son particularmente adecuadas para el enfoque supervisado de IAm Phideus. • **Modelos de espacio de estados (Mamba) y SSAMBA:** Los transformadores han sido dominantes en tareas de audio, pero su costo computacional cuadrático es elevado. Los modelos de espacio de estados, como Mamba, permiten capturar dependencias de largo alcance de manera eficiente. SSAMBA es una variante auto-supervisada para audio que elimina la atención explícita y supera al Transformer de espectrogramas auto-supervisado (SSAST) ofreciendo mayor eficiencia en memoria y tiempo [539959136651807†L35-L54]. Preentrenando sobre espectrogramas de audio de manera contrastiva, SSAMBA obtiene representaciones robustas y escalables [539959136651807†L69-L124]. • **Transformadores con aprendizaje contrastivo e Investigaciones recientes** muestran que un transformador en versión 1D entrenado mediante aprendizaje autosupervisado contrastivo (similar a SimCLR) revela propiedades musicales emergentes. Los tokens de cada token capturan información útil para tareas de armonización y la arquitectura puede representar simultáneamente características locales y globales sin supervisión explícita [879604189399424†L30-L48]. Esto sugiere que métodos contrastivos aplicados a histogramas de razones pueden descubrir estructuras musicales intrínsecas. • **Perceiver y Perceiver IO:** El Perceiver es un modelo basado en transformadores que emplea un cuello de botella de atención asimétrica para destilar entradas de alta dimensionalidad en un conjunto pequeño de variables latentes. Este mecanismo reduce la complejidad cuadrática de la atención y permite procesar imágenes, audio y video en un único modelo, alcanzando competitividad con modelos especializados [200672702072258†L14-L30]. La versión Perceiver IO admite salidas de forma variable y podría integrarse como codificador general en el flujo de IAm Phideus para procesar histogramas de largo o señales sin presuponer estructura convolutiva. • **Modelos de difusión para audio:** Los modelos de difusión (denoising diffusion probabilistic models y score-based generative models) han convertido en el estado del arte para la síntesis de audio de alta fidelidad y para tareas como vocoding, text-to-speech y separación de fuentes. Su capacidad para generar muestras condicionadas con fidelidad superior los hace atractivos para crear conjuntos sintéticos de datos que respeten la estructura estadística del dominio [791420095078562†L81-L114]. • **Redes convolucionales de atención temporo-frecuencia:** El método TFCNN introduce mecanismos de atención en el eje de frecuencia sobre espectrogramas para enfocarse en las bandas y marcos más relevantes, mejorando la clasificación de sonidos ambientales frente al ruido [490245557176724†L74-L87]. • **Aprendizaje contrastivo de representaciones auditivas (CLAR):** CLAR extiende SimCLR al dominio auditivo mediante una combinación de aumentos de datos y entrenamiento mixto que combina pérdidas contrastivas y supervisadas. Demuestra que el uso de características tiempo-frecuencia mejora las representaciones y que la combinación de objetivos reduce el tiempo de convergencia y aumenta la precisión en la clasificación [158086294726326†L23-L39] [158086294726326†L118-L124].

3. Propuesta de arquitectura

Propuesta de arquitectura para IAm Phideus La naturaleza del proyecto requiere descubrir patrones de relaciones armónicas sin conocimiento previo sobre escalas humanas. Basándonos en los documentos internos y en los avances recientes, proponemos la siguiente arquitectura híbrida:

****Preprocesamiento:**** 1. Captura de la señal en ventanas de múltiples resoluciones mediante STFT. 2. Detección de picos espectrales y cálculo exhaustivo de las razones de frecuencia f_i/f_j para cada par de picos dentro de cada ventana. 3. Construcción de histogramas de razones: se genera un histograma lineal de alta resolución (ratio_hist_lin) para evitar sesgos musicales y un histograma logarítmico opcional (ratio_hist_log). Cada histograma se normaliza. ****Codificación latente con β -VAE y dilated CNN:**** 4. Se utiliza un β -Variational Autoencoder con convoluciones 1D dilatadas sobre ratio_hist_lin para aprender una representación latente compacta. El hiperparámetro β regula la penalización KL, permitiendo eliminar dimensiones redundantes y captar únicamente patrones armónicos esenciales. La annealing gradual del peso KL promueve un aprendizaje estable. 5. La parte decodificadora del VAE reconstruye el histograma y actúa como generador, permitiendo sintetizar histogramas plausibles como datos de entrenamiento. Se utilizan técnicas de aumento (jitter, ruido gaussiano) y regularización para mejorar la variación. ****Clasificación y aprendizaje contrastivo:**** 6. La representación latente se alimenta a un clasificador 1D con convoluciones dilatadas o a un modelo de espacio de estados (Mamba) según la longitud de la secuencia. Las convoluciones dilatadas permiten captar relaciones a distintas escalas mientras que Mamba captura dependencias de largo alcance de forma eficiente. 7. Paralelamente, se entrena un módulo contrastivo inspirado en CLAR y SSAMBA: se generan distintas vistas de ratio_hist_lin mediante aumentaciones (permutaciones de picos, ruido) y se maximizan las similitudes entre vistas del mismo ejemplo y se minimiza entre ejemplos diferentes. Se puede combinar con la pérdida supervisada usando una capa de clasificación para etiquetas experimentales. Esto ayuda a que las representaciones latentes sean robustas y capturen estructura global. ****Integración Perceiver/Mamba:**** 8. Para señales de mayor duración o con información adicional (por ejemplo, secuencias temporales de histogramas), se puede integrar un Perceiver para mapear entradas de alta dimensionalidad a un espacio latente compacto gracias a su cuello de botella de atención. Alternativamente, un módulo Mamba preentrenado en audio puede reemplazar la CNN del clasificador para procesar histogramas como secuencias, aprovechando su eficiencia en memoria y capacidad para capturar dependencias a largo plazo. ****Generación de datos y difusión:**** 9. Con los histogramas reconstruidos por el decodificador del VAE y modelos de difusión de audio, se pueden generar señales sintéticas que respeten las estadísticas armónicas de la naturaleza. La síntesis mediante modelos de difusión permite producir datos adicionales de alta fidelidad para mejorar el entrenamiento y evaluar la capacidad del sistema para reconocer patrones en condiciones controladas. Esta arquitectura combina aprendizaje no supervisado (β -VAE), supervisado y contrastivo, captura tanto relaciones locales como globales, y permite escalar a secuencias largas mediante modelos de espacio de estados o Perceiver. Además, la capacidad generativa del VAE y de los modelos de difusión facilita la generación de conjuntos sintéticos de entrenamiento que preservan la estructura de relaciones armónicas.



4. Conclusiones y trabajos futuros

Conclusiones y trabajos futuros La propuesta aquí detallada integra los hallazgos más relevantes de la literatura reciente con las necesidades específicas de IAm Phideus. El uso de un β -VAE con convoluciones dilatadas permite descomponer histogramas de relaciones de frecuencia en un espacio latente interpretable y al mismo tiempo generar datos sintéticos. La incorporación de modelos de espacio de estados como Mamba o arquitecturas Perceiver permite escalar a secuencias largas sin sufrir los costos cuadráticos de los transformadores, mientras que el aprendizaje contrastivo garantiza que las representaciones obtenidas sean robustas y generalicen entre diferentes contextos armónicos. En trabajos futuros se propone explorar la integración de grafos para modelar relaciones entre picos espectrales, analizar el impacto de diversas funciones de activación en la disentanglement del β -VAE y evaluar la transferencia del modelo a otros dominios como señales biológicas (por ejemplo, ritmos cerebrales). Además, se sugiere investigar versiones ligeras de modelos de difusión que permitan generación condicional de histogramas con bajo costo computacional.